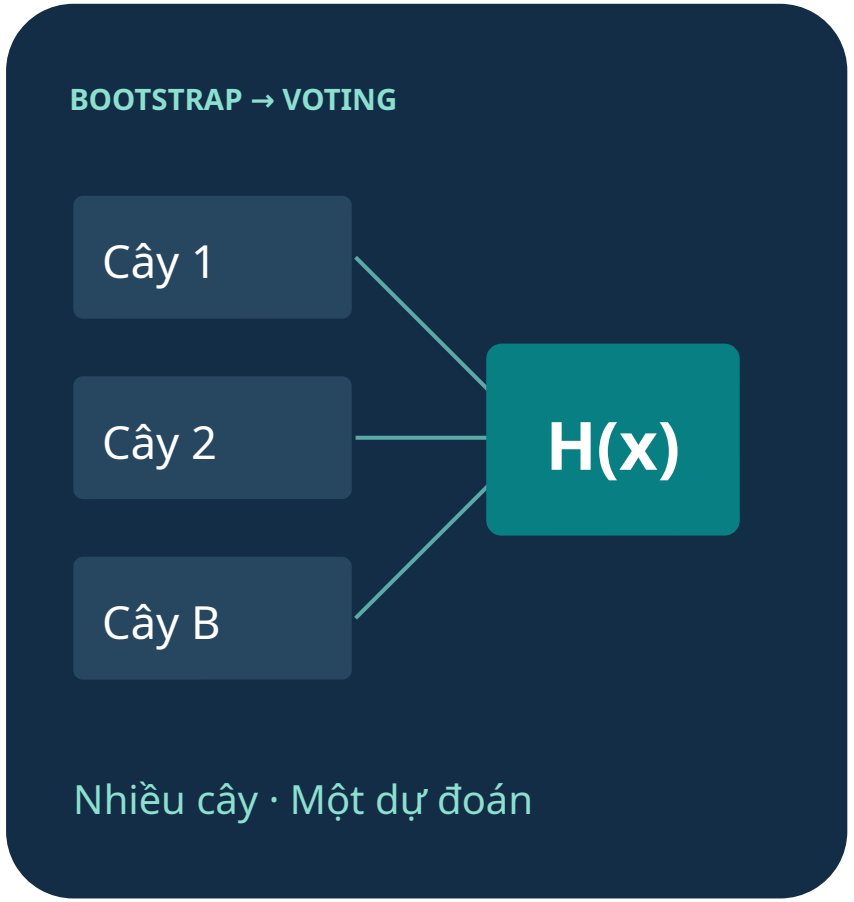
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

ENSEMBLE LEARNING

Trọng tâm: Bagging cây quyết định
Mở rộng: AdaBoost, Voting, Stacking



Nguyễn Nghĩa Hiếu · 52400013
Trần Quốc Bảo · 52400102
Giảng viên: TS. Trần Lương Quốc Đại

Bagging trong bức tranh học tổ hợp

Bagging

Bootstrap
Học độc lập

TRỌNG TÂM TRIỂN KHAI

Boosting

Học tuần tự
Giảm sai số / loss

AdaBoost / Gradient Boosting

Voting

Kết hợp nhãn
hoặc xác suất

Hard / Soft

Stacking

Dự đoán OOF
→ học tầng hai

Meta-model

Bagging được triển khai sâu; ba hướng còn lại có minh họa và thực nghiệm.

[1], [2], [3], [6], [7]

AdaBoost: mẫu sai được tăng trọng số tương đối

1 Khởi tạo trọng số đều

Mỗi quan sát train có trọng số 1/N.

2 Học cây nông có trọng số

Tính sai số có trọng số ε của cây.

3 Tính trọng số của cây

SAMME nhị phân: $\alpha = \ln((1 - \varepsilon)/\varepsilon)$.

4 Cập nhật rồi học tiếp

Tăng trọng số mẫu sai, chuẩn hóa tổng = 1.

VÍ DỤ: E = 0,2; LEARNING RATE = 1

$$\alpha = \ln 4 \approx 1{,}386$$

Nhóm	Trước	Nhân	Chuẩn hóa
Dự đoán sai	20%	×4	50%
Dự đoán đúng	80%	×1	50%

Trọng số thay đổi; chưa phải accuracy tăng.

Thực nghiệm: tối đa 51 cây một mức; tổng hợp theo trọng số của từng cây.

Voting dùng quy tắc; Stacking học cách kết hợp

Cùng ba loại mô hình: cây độ sâu 3 · Logistic Regression · Gaussian NB

VOTING

Học ba mô hình trên train.

Hard: đếm nhãn, trọng số bằng nhau.

Soft: trung bình xác suất lớp.

Quy tắc cố định, không học tầng hai.

STACKING

Tạo dự đoán ngoài fold (OOF).

Học Logistic Regression tầng hai.

Học lại mô hình cơ sở trên toàn train.

OOF: dự đoán cho mẫu chưa dùng để học.

Stacking: CV 5 fold trong train; StandardScaler nằm trong pipeline của Logistic Regression.

[3], [7] · VotingClassifier / StackingClassifier

Bagging = Bootstrap + Aggregating

BƯỚC 1

Giữ riêng test

Chỉ lấy mẫu
từ tập train.

➡

BƯỚC 2

Tạo bootstrap

N lượt lấy
có hoàn lại / cây.

➡

BƯỚC 3

Học B cây

Một cây học
trên mỗi bootstrap.

➡

BƯỚC 4

Đếm phiếu

Cùng một mẫu mới
→ chọn lớp đa số.

Mỗi bootstrap lấy N lượt có hoàn lại từ cùng tập train.

[1], [3] · ensemble_model.py

Cùng 5 quan sát, tạo 3 bootstrap khác nhau

DỮ LIỆU GỐC

x = 1	x = 2	x = 3	x = 4	x = 5
Lành	Lành	Ác	Ác	Ác

Cây	Chỉ số bootstrap (từ 0)	Quan sát vắng mặt
h1	[0, 0, 2, 4, 1]	3
h2	[0, 0, 1, 3, 4]	2
h3	[4, 2, 4, 1, 3]	0

Có lặp, có quan sát vắng mặt; tổng số lượt lấy vẫn bằng N.

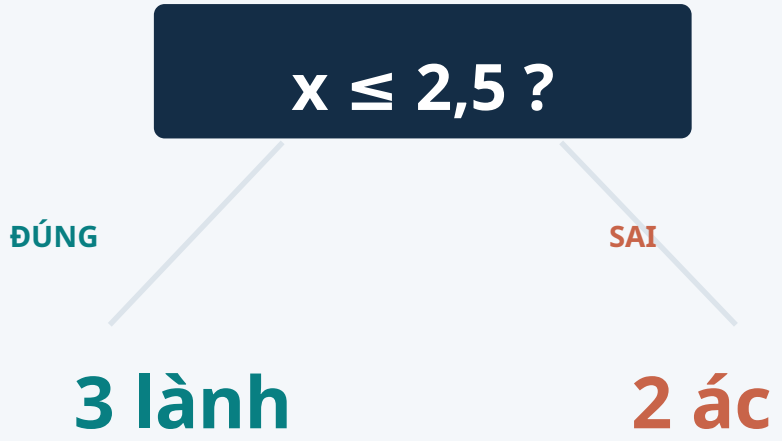
Cây h_1 chọn ngưỡng làm giảm Gini nhiều nhất

TRƯỚC KHI CHIA

3 lành + 2 ác

$$\text{Gini} = 1 - (3/5)^2 - (2/5)^2$$
$$= 0{,}48$$

Ngưỡng	Gini sau chia
1,5 / 2,5 / 4,0	0,2667 / 0 / 0,30



Cả hai nhánh: Gini = 0

Ngưỡng 2,5: Gini giảm từ 0,48 xuống 0.

Mẫu x = 2,8 nhận hai phiếu ác và một phiếu lành

CÂY H1

2,8 > 2,5

Ác tính

CÂY H2

2,8 ≤ 3,0

Lành tính

CÂY H3

2,8 > 2,5

Ác tính

2 : 1

Hard voting chọn ác tính (0).

Ví dụ giả lập, chưa có nhãn thật; tỷ lệ phiếu không phải xác suất bệnh.

Hard và soft voting có thể chọn khác lớp

Đầu ra từng mô hình	Cây 1	Cây 2	Cây 3
P(ác tính)	0,51	0,51	0,01
Nhãn dự đoán	Ác	Ác	Lành

HARD → ÁC

2 phiếu ác / 3 cây

SOFT → LÀNH

P(ác) trung bình = 0,343

Hard đếm nhãn; soft trung bình xác suất.

OOB chỉ dùng phiếu của cây chưa học quan sát đó

Cây 1: có mẫu i	**Không tính**
Cây 2: vắng mẫu i	**Được bỏ phiếu**
Cây 3: vắng mẫu i	**Được bỏ phiếu**

94,13%

Accuracy OOB

401/426 dự đoán đúng

Coverage 100%

Mỗi mẫu: 8–34 phiếu OOB

OOB là đánh giá bổ sung, được tính sau chọn độ sâu.

569 mẫu: học trên train, đánh giá trên test

569

quan sát

30

đặc trưng số

2

lớp: ác (0), lành (1)

TRAIN 426 MẪU · 75%

CV 5 fold → **Độ sâu 3**

TEST GIỮ RIÊNG

143 mẫu

Chọn độ sâu bằng cây đơn trên train, rồi dùng chung cho ba mô hình.

Bootstrap được triển khai trực tiếp trong Python

PYTHON · TRÍCH LƯỢC

```
indices = rng.integers(
    0, n_samples, size=n_samples
)
tree = DecisionTreeClassifier(
    max_depth=self.max_depth,
    random_state=int(rng.integers(0, 2**31 - 1)),
)
tree.fit(X[indices], encoded[indices])
self.estimators_.append(tree)
```

01

Lấy có hoàn lại

Có thể lặp chỉ số.

02

Seed riêng từng cây

Hỗ trợ tái lập.

03

Đúng cặp X và y

Dùng cùng indices.

Tự triển khai Bagging; cây cơ sở dùng scikit-learn.

Hard voting đếm phiếu rồi ánh xạ về nhãn gốc

PYTHON · TRÍCH LƯỢC

```
counts = np.zeros(
    (len(X), len(self.classes_)), dtype=np.int64
)
rows = np.arange(len(X))
for tree in self.estimators_:
    predicted = tree.predict(X).astype(int)
    np.add.at(counts, (rows, predicted), 1)
labels = self.classes_[counts.argmax(axis=1)]
```

Mỗi hàng = một quan sát

Mỗi cột = một lớp

Tổng phiếu / hàng = B

Mỗi cây bỏ một phiếu; argmax chọn lớp có nhiều phiếu nhất.

Seed 42: Bagging đúng thêm 1/143 mẫu test

Mô hình	Accuracy	Recall ác
Cây đơn	94,41%	90,57%
Bagging	**95,10%**	**92,45%**
Random Forest	95,10%	92,45%

MA TRẬN BAGGING

		DỰ ĐOÁN: Ác	DỰ ĐOÁN: Lành
	Thật ác	49	4
	Thật lành	3	87

Bỏ sót ác: 5 → 4

Dương tính giả: 3

Bagging vẫn bỏ sót 4/53 mẫu ác; một lần chia chưa đủ kết luận ưu thế tổng quát.

Bagging cao hơn cây đơn ở 9/10 lần chia

Mô hình	Accuracy (%)	Recall ác (%)
Cây đơn	92,80 ± 1,84	90,38 ± 4,66
Bagging	**94,76 ± 1,59**	**92,45 ± 3,77**
Random Forest	95,03 ± 1,85	92,26 ± 3,26

+1,96 đpt

Accuracy trung bình so với cây đơn.

So với RF: chưa có ưu thế nhất quán.

Trung bình ± SD mẫu; các test có thể giao nhau. SD chưa phải khoảng tin cậy.

So sánh các cơ chế trên cùng mười lần chia

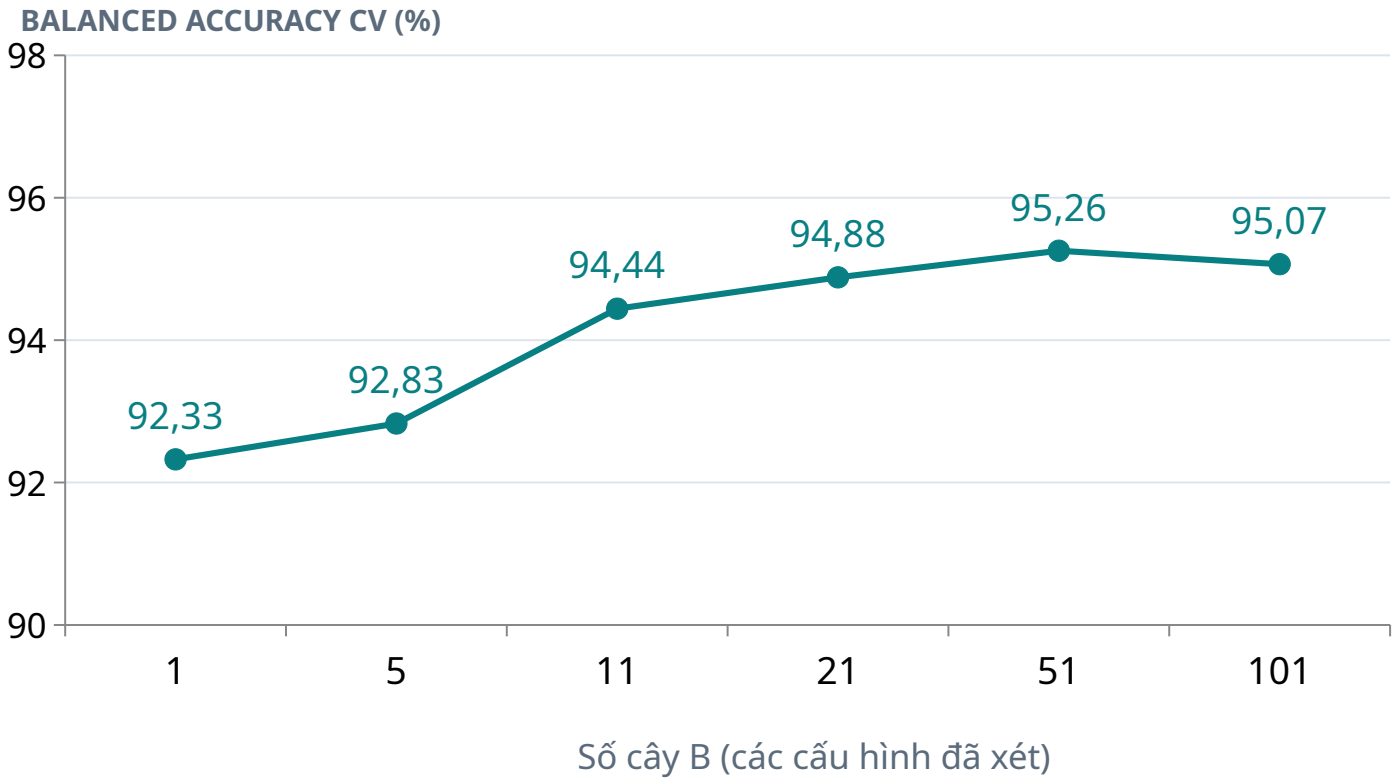
Mô hình	Accuracy (%)	Recall ác (%)
Bagging tự triển khai	**94,76 ± 1,59**	**92,45 ± 3,77**
AdaBoost	96,43 ± 1,07	94,15 ± 2,08
Voting hard	95,80 ± 1,23	92,64 ± 3,72
Voting soft	95,66 ± 1,27	92,64 ± 3,72
Stacking	96,64 ± 1,22	95,09 ± 2,70

LR đơn: accuracy 97,62 ± 0,82% — cao nhất trong cấu hình khảo sát.

Cấu hình cố định, khác nhau giữa các mô hình; phân tích hậu nghiệm, không phải xác nhận độc lập.

family_comparison.json · 10 holdout seed 42–51 · trung bình ± SD mẫu

Tăng số cây có lợi, nhưng chưa tăng mãi



51 CÂY

95,26 ± 2,45

BA CV (%) · trung bình ± SD

101 cây: 95,07%

Chưa cải thiện thêm.

Khảo sát trên train; 51 cây chưa được chứng minh tối ưu tổng quát.

outputs/extensions/analysis.json · CV ngoài 5 fold · không dùng test

Tổ hợp 51 cây vẫn có thể dự đoán sai

NHÃN THẬT: LÀNH TÍNH

27 phiếu ác / 24 phiếu lành

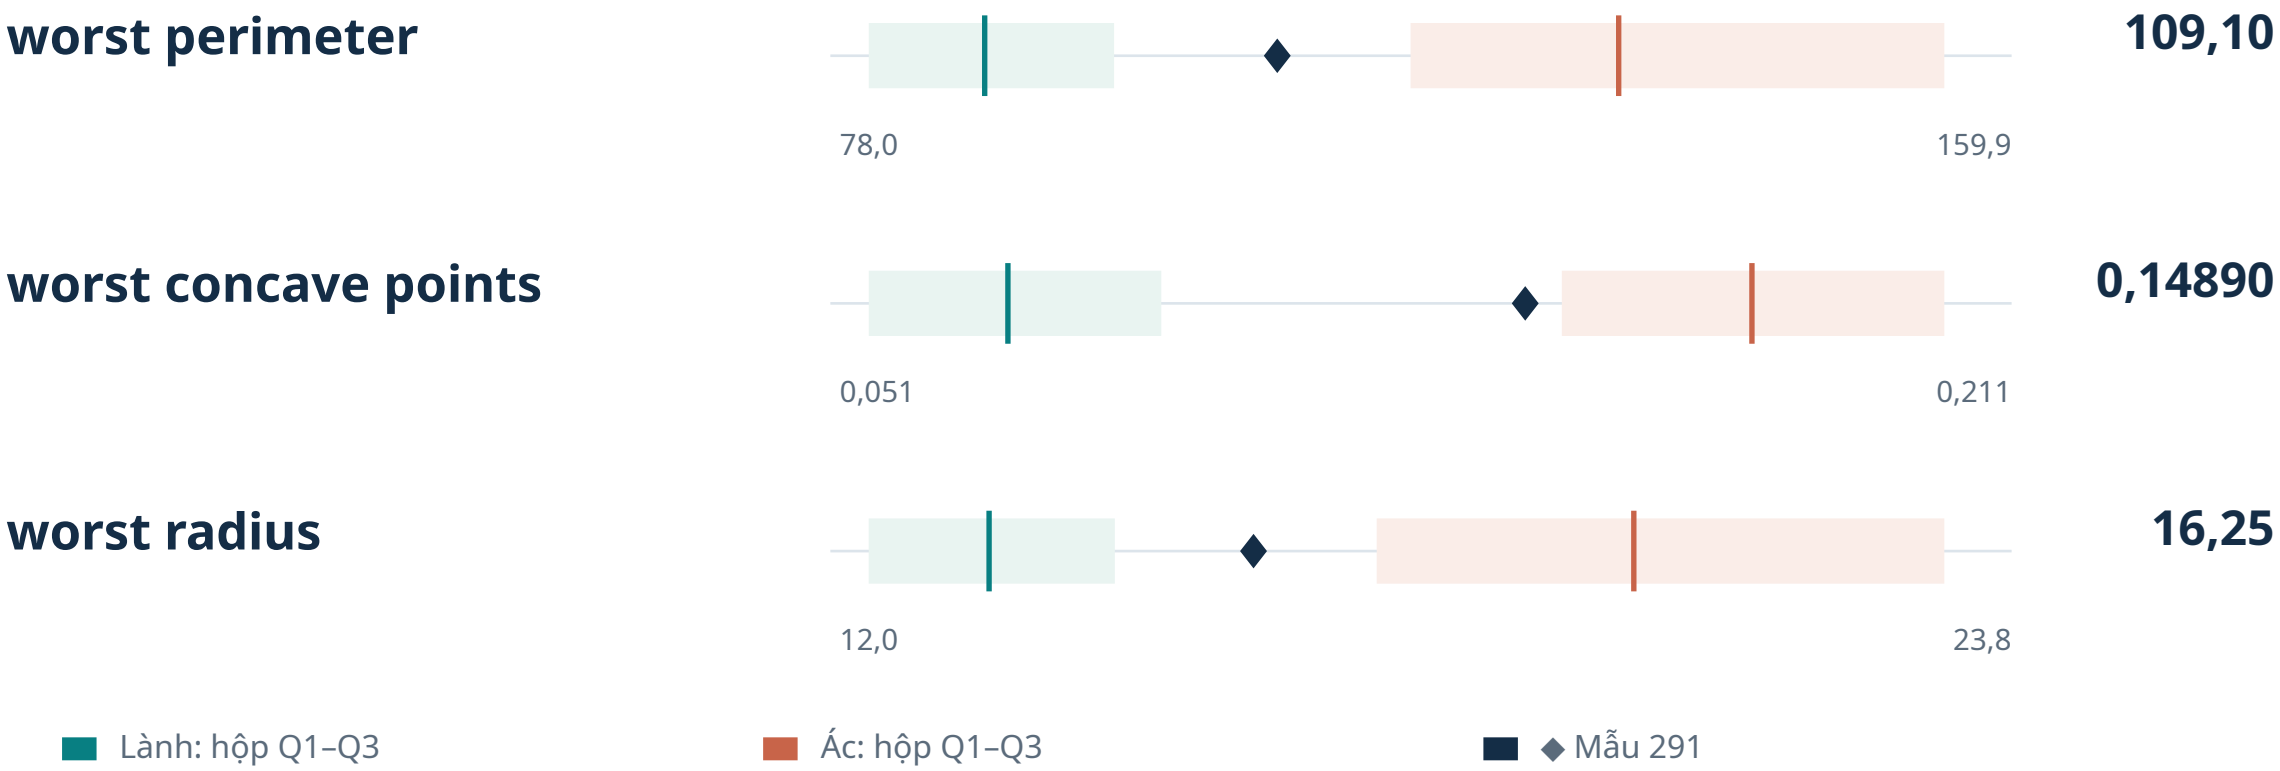


Đa số chọn ác → dương tính giả

Biên phiếu
3/51 ≈ 5,88%

Mẫu đầu tiên có hai phía phiếu, được chọn theo thứ tự test.

Mẫu sai nằm giữa các vùng trung tâm của hai lớp



Mỗi hàng có thang riêng; ba đặc trưng chỉ cung cấp một phần giải thích.

Đặc trưng chọn theo tần suất nút gốc trên train · outputs/extensions/analysis.json

Hard/soft gần nhau; sqrt chưa cải thiện

426 train · 51 cây · Cùng fold, bootstrap và seed từng cây

Xét đặc trưng	Tổng hợp	Balanced accuracy CV (%)
Toàn bộ	**Hard**	**95,26 ± 2,45**
Toàn bộ	**Soft**	**95,26 ± 2,45**
sqrt	Hard	93,62 ± 3,48
sqrt	Soft	93,44 ± 3,77

Nhóm sqrt tự xây khác RF sklearn; SD giữa các fold chưa phải khoảng tin cậy.

controlled_comparison_summary.csv · BA CV trung bình ± SD qua 5 fold

Đa dạng hơn chưa đủ: cây cơ sở cũng phải đủ tốt

BẤT ĐỒNG GIỮA CÁC CÂY

7,99%

→ 10,52%

D tăng khi dùng sqrt

CHẤT LƯỢNG MỘT CÂY

91,67%

→ 89,75%

Balanced accuracy trung bình giảm

Tổ hợp hard: 95,26% → 93,62%, trong cấu hình đang khảo sát.

controlled_comparison_summary.csv · số trung bình qua 5 fold

Tái lập được; kết luận có giới hạn

Chưa tuning riêng

Cấu hình cố định
ở phần mở rộng.

Các holdout giao nhau

SD mô tả dao động,
chưa phải khoảng tin cậy.

Thiết kế hậu nghiệm

Đã xem kết quả gốc;
chưa có xác nhận ngoài.

Kiểm thử tự động

github.com/Huyngaongow/hocmaygk

Mục đích học thuật; chưa đánh giá khả năng chẩn đoán lâm sàng.

Ba kết luận từ dữ liệu đã khảo sát

01

Bagging cải thiện so với cây đơn

9/10 lần chia cao hơn cây đơn; trung bình +1,96 đpt.

02

Mở rộng không tự động tốt hơn

LR đơn có accuracy cao nhất ở các cấu hình đã khảo sát.

03

Đa dạng đi cùng chất lượng

Khác nhau hơn chưa chắc dự đoán tốt hơn.

A. Cùng mẫu 291, hai cây đi tới hai nhãn

CÂY 1 → ÁC

1. worst radius ≤ 16,79500
2. worst concave points > 0,14315
3. worst symmetry > 0,28855

Lá: 18 lượt bootstrap, tất cả nhãn ác.

CÂY 2 → LÀNH

1. mean concave points ≤ 0,04989
2. worst symmetry > 0,16385
3. worst perimeter ≤ 127,20000

Lá: 256/259 lượt nhãn lành (98,84%).

Các lượt bootstrap có thể lặp hàng; độ thuần tại lá không bảo đảm đúng với quan sát mới.

B. Tính chỉ số với ác tính là lớp dương

Chỉ số	Công thức	Kết quả
Accuracy	(TP + TN) / N	136/143 = 95,10%
Precision ác	TP / (TP + FP)	49/52 = 94,23%
Recall ác	TP / (TP + FN)	49/53 = 92,45%
F1 ác	2TP / (2TP + FP + FN)	98/105 = 93,33%
Specificity	TN / (TN + FP)	87/90 = 96,67%
Balanced accuracy	Trung bình recall hai lớp	94,56%

Accuracy test, balanced accuracy CV và OOB là các phép đánh giá khác nhau.

C. Đủ mười mô hình và các đối chứng đơn

Mô hình / cấu hình	Accuracy (%)	Recall ác (%)
Cây đơn (CV chọn độ sâu)	92,80 ± 1,84	90,38 ± 4,66
Bagging tự triển khai	94,76 ± 1,59	92,45 ± 3,77
Random Forest (sklearn)	95,03 ± 1,85	92,26 ± 3,26
Cây đơn (độ sâu cố định 3)	92,94 ± 2,15	90,19 ± 4,86
Logistic Regression	97,62 ± 0,82	96,60 ± 2,32
Gaussian NB	94,20 ± 1,40	90,19 ± 4,15
AdaBoost	96,43 ± 1,07	94,15 ± 2,08
Voting (hard)	95,80 ± 1,23	92,64 ± 3,72
Voting (soft)	95,66 ± 1,27	92,64 ± 3,72
Stacking	96,64 ± 1,22	95,09 ± 2,70

Không mặc định tổ hợp tốt hơn mô hình đơn; chưa có kiểm định hay dữ liệu xác nhận ngoài độc lập.

D. Tài liệu tham khảo và cách tái lập

[1] Breiman (1996). Bagging Predictors. Machine Learning 24, 123–140.

[2] Breiman (2001). Random Forests. Machine Learning 45, 5–32.

[3] scikit-learn User Guide. Ensemble methods.

[4] scikit-learn API. load_breast_cancer.

[5] scikit-learn User Guide. Decision Trees.

[6] Freund & Schapire (1997). An Application to Boosting. JCSS 55(1).

[7] Wolpert (1992). Stacked Generalization. Neural Networks 5(2).

```
python de_5_ensemble_learning.py
python experiments/report_extensions.py
python experiments/controlled_comparison.py
python experiments/ensemble_families.py
```