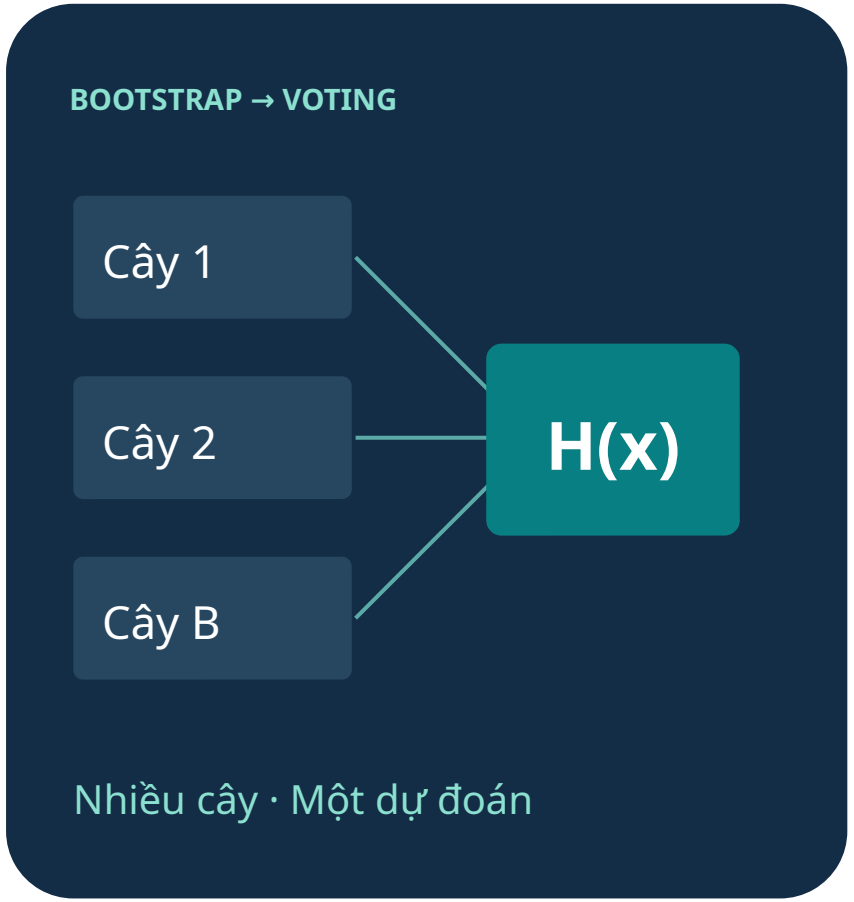
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

ENSEMBLE LEARNING

Bagging cây quyết định trong phân loại u vú

Nguyễn Nghĩa Hiếu · 52400013
Trần Quốc Bảo · 52400102
Giảng viên: TS. Trần Lương Quốc Đại



Ba câu hỏi dẫn dắt báo cáo

01

Có cải thiện không?

Bagging so với một cây đơn trên cùng các lần chia dữ liệu.

02

Bao nhiêu cây là đủ?

Khảo sát số cây trên train; xem lợi ích có tiếp tục tăng.

03

Khác nhau thế nào là tốt?

Tách ảnh hưởng của đặc trưng
và cách tổng hợp dự đoán.

Mạch trình bày: cơ chế → ví dụ → triển khai → bằng chứng thực nghiệm.

Bagging trong bức tranh học tổ hợp

Bagging

Đổi mẫu train
Học các cây độc lập
Tổng hợp dự đoán

TRỌNG TÂM TRIỂN KHAI

Boosting

Học tuần tự
Xử lý sai sót hoặc
giảm hàm mất mát

AdaBoost / Gradient Boosting

Voting

Kết hợp đầu ra
Đa số nhãn hoặc
trung bình xác suất

Hard / Soft

Stacking

Dự đoán ngoài fold
Tạo đầu vào cho
mô hình tầng hai

Meta-model

Các hướng không tách rời: Bagging vẫn cần một quy tắc tổng hợp như voting.

[1], [2], [3], [6], [7]

Bagging = Bootstrap + Aggregating

BƯỚC 1

Giữ riêng test

Chỉ lấy mẫu
từ tập train.

BƯỚC 2

➡ Tạo bootstrap

N lượt lấy
có hoàn lại / cây.

BƯỚC 3

➡ Học B cây

Một cây học
trên mỗi bootstrap.

BƯỚC 4

➡ Đếm phiếu

Cùng một mẫu mới
→ chọn lớp đa số.

Không chia train thành B phần rời nhau. Mỗi bootstrap đều lấy từ cùng tập train.

[1], [3] · ensemble_model.py

Cùng 5 quan sát, tạo 3 bootstrap khác nhau

DỮ LIỆU GỐC

x = 1	x = 2	x = 3	x = 4	x = 5
Lành	Lành	Ác	Ác	Ác

Cây	Chỉ số bootstrap (từ 0)	Quan sát vắng mặt
h1	[0, 0, 2, 4, 1]	3
h2	[0, 0, 1, 3, 4]	2
h3	[4, 2, 4, 1, 3]	0

Ví dụ h_1 lấy chỉ số 0 hai lần và không lấy chỉ số 3. Mỗi bootstrap vẫn có 5 lượt.

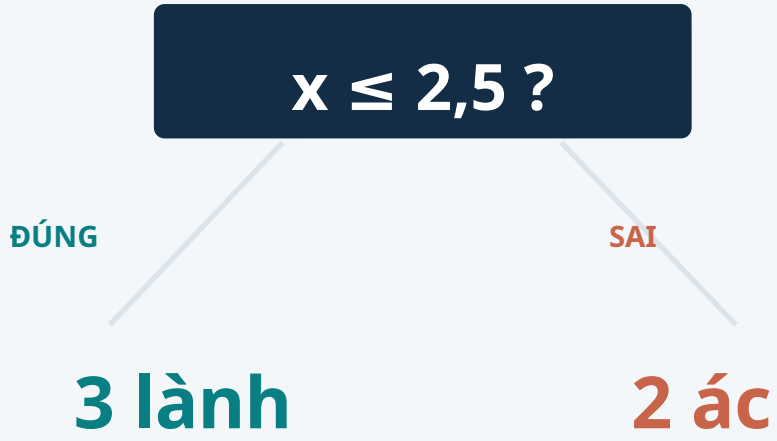
Cây h_1 chọn ngưỡng làm giảm Gini nhiều nhất

TRƯỚC KHI CHIA

3 lành + 2 ác

$$\text{Gini} = 1 - (3/5)^2 - (2/5)^2$$
$$= 0{,}48$$

Ngưỡng	Gini sau chia
1,5 / 2,5 / 4,0	0,2667 / 0 / 0,30



Cả hai nhánh: Gini = 0

Ngưỡng 2,5 cho Gini sau chia bằng 0; mức giảm đạt 0,48.

Mẫu x = 2,8 nhận hai phiếu ác và một phiếu lành

CÂY H1

2,8 > 2,5

Ác tính

CÂY H2

2,8 ≤ 3,0

Lành tính

CÂY H3

2,8 > 2,5

Ác tính

2 : 1

Hard voting chọn ác tính (0).

Mẫu toy chưa có nhãn thật: chưa thể nói đúng/sai; 2/3 phiếu không phải xác suất bệnh.

Hard và soft voting có thể chọn khác lớp

Đầu ra từng mô hình	Cây 1	Cây 2	Cây 3
P(ác tính)	0,51	0,51	0,01
Nhãn dự đoán	Ác	Ác	Lành

HARD → ÁC

2 phiếu ác / 3 cây

SOFT → LÀNH

P(ác) trung bình = 0,343

Thay quy tắc tổng hợp chưa chắc tốt hơn; cần kiểm tra trên cùng những cây đã học.

OOB chỉ dùng phiếu của cây chưa học quan sát đó

Cây 1: có mẫu i	**Không tính**
Cây 2: vắng mẫu i	**Được bỏ phiếu**
Cây 3: vắng mẫu i	**Được bỏ phiếu**

94,13%

Accuracy OOB

401/426 dự đoán đúng

Coverage 100%

Mỗi mẫu: 8–34 phiếu OOB

OOB được tính sau chọn độ sâu trên train; là đánh giá bổ sung, chưa độc lập với tuning.

Bài toán phân loại trên 569 quan sát

569

quan sát

Dữ liệu công khai

30

đặc trưng số

Đặc điểm nhân tế bào

2

lớp dự đoán

Ác tính (0) / lành tính (1)



212 ác tính · lớp dương = 0

357 lành tính · nhãn 1

Đầu vào là các đặc trưng đã trích xuất, không phải ảnh gốc. Mục đích minh họa học máy.

Chọn độ sâu trên train, giữ test bên ngoài

TRAIN 426 mẫu · 159 ác / 267 lành

1. **CV phân tầng 5 fold**
   Thử max_depth từ 2 đến 6.

2. **Chọn độ sâu 3**
   Balanced accuracy CV: 93,73%.

TEST GIỮ RIÊNG

143

53 ác / 90 lành
Chỉ đánh giá sau
khi chốt cấu hình.

Độ sâu chọn bằng cây đơn rồi dùng chung cho ba mô hình; chưa tối ưu riêng từng ensemble.

Bootstrap được triển khai trực tiếp trong Python

PYTHON · TRÍCH LƯỢC

```
indices = rng.integers(
    0, n_samples, size=n_samples
)
tree = DecisionTreeClassifier(
    max_depth=self.max_depth,
    random_state=int(rng.integers(0, 2**31 - 1)),
)
tree.fit(X[indices], encoded[indices])
self.estimators_.append(tree)
```

01

Lấy có hoàn lại

Có thể lặp chỉ số.

02

Seed riêng từng cây

Hỗ trợ tái lập.

03

Đúng cặp X và y

Dùng cùng indices.

Cây cơ sở dùng scikit-learn; bootstrap, tổ chức các cây và OOB do nhóm triển khai.

Hard voting đếm phiếu rồi ánh xạ về nhãn gốc

PYTHON · TRÍCH LƯỢC

```
counts = np.zeros(
    (len(X), len(self.classes_)), dtype=np.int64
)
rows = np.arange(len(X))
for tree in self.estimators_:
    predicted = tree.predict(X).astype(int)
    np.add.at(counts, (rows, predicted), 1)
labels = self.classes_[counts.argmax(axis=1)]
```

Mỗi hàng = một quan sát

Mỗi cột = một lớp

Tổng phiếu / hàng = B

26/26 kiểm thử đạt: bootstrap, voting, OOB, nhãn, tái lập và quy trình đánh giá.

Seed 42: Bagging đúng thêm 1 trên 143 mẫu test

Mô hình	Accuracy	Recall ác	F1 ác
Cây đơn	94,41%	90,57%	92,31%
Bagging tự viết	**95,10%**	**92,45%**	**93,33%**
Random Forest	95,10%	92,45%	93,33%

Cây đơn: 135/143 đúng

Bagging: 136/143 đúng

Chênh lệch accuracy: +0,70 điểm phần trăm. Một lần chia chưa đủ kết luận ưu thế tổng quát.

outputs/results.json · test n = 143 · lớp dương: ác tính (0)

Số ca ác tính bị bỏ sót giảm từ 5 xuống 4

CÂY ĐƠN

	DỰ ĐOÁN: Ác	DỰ ĐOÁN: Lành
Thật ác	48	5
Thật lành	3	87

BAGGING

	DỰ ĐOÁN: Ác	DỰ ĐOÁN: Lành
Thật ác	49	4
Thật lành	3	87

Bagging vẫn bỏ sót 4/53 mẫu ác tính; số dương tính giả giữ nguyên là 3.

Seed 42 · hàng = nhãn thật · cột = dự đoán

Bagging cao hơn cây đơn ở 9/10 lần chia

Mô hình	Accuracy (%)	Recall ác (%)	F1 ác (%)
Cây đơn	92,80 ± 1,84	90,38 ± 4,66	90,30 ± 2,42
Bagging	**94,76 ± 1,59**	**92,45 ± 3,77**	**92,89 ± 2,13**
Random Forest	95,03 ± 1,85	92,26 ± 3,26	93,26 ± 2,39

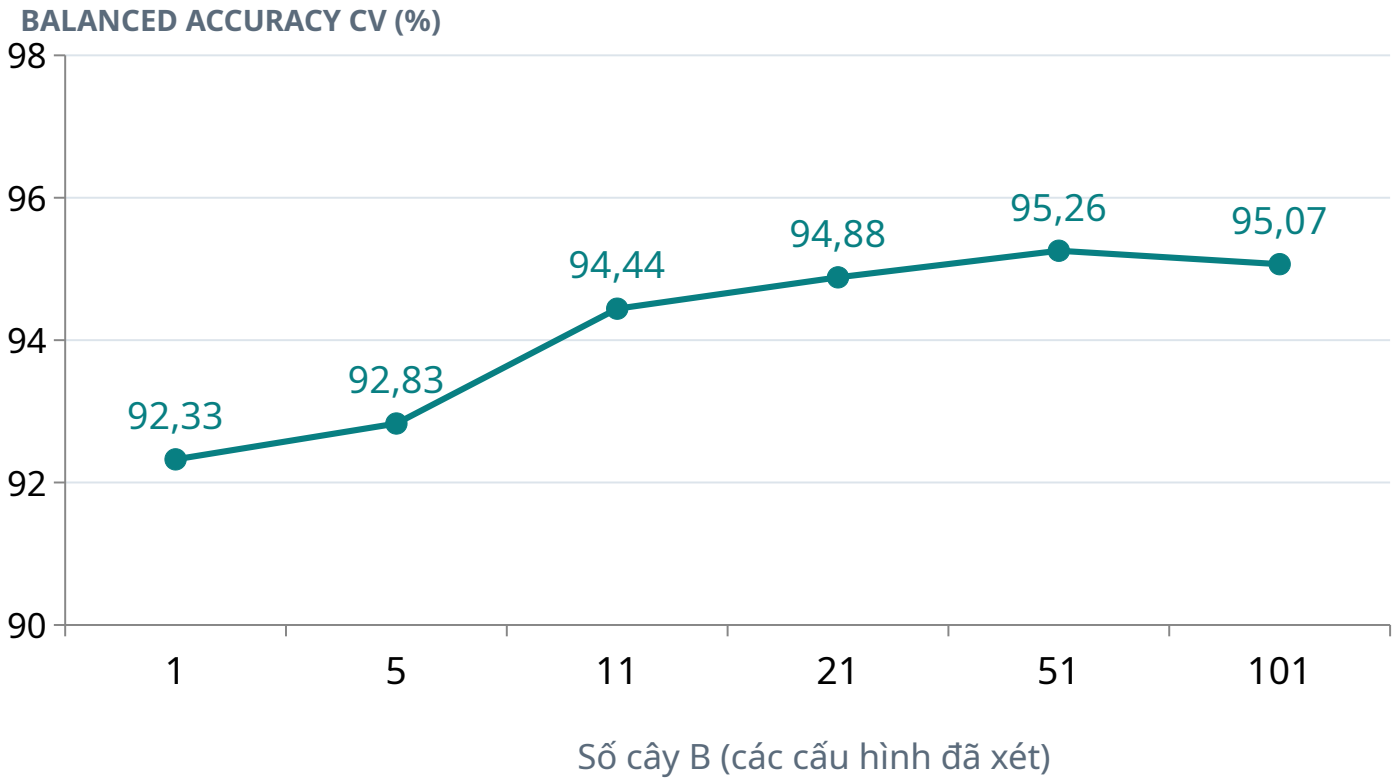
+1,96 đpt

Accuracy trung bình Bagging − cây đơn.
So với RF: 2 thắng / 4 hòa / 4 thua.

Trung bình ± SD mẫu; các test có thể giao nhau. Chưa có kiểm định ý nghĩa thống kê.

outputs/results.json · controlled_comparison.json · seed 42–51

Tăng số cây có lợi, nhưng chưa tăng mãi



51 CÂY

95,26 ± 2,45

BA CV (%) · trung bình ± SD

101 cây: 95,07%

Chưa cải thiện thêm.

51 là cấu hình ban đầu; khảo sát bổ sung chưa chứng minh đó là số cây tối ưu tổng quát.

outputs/extensions/analysis.json · CV ngoài 5 fold · không dùng test

Tổ hợp 51 cây vẫn có thể dự đoán sai

NHÃN THẬT: LÀNH TÍNH

27 phiếu ác / 24 phiếu lành

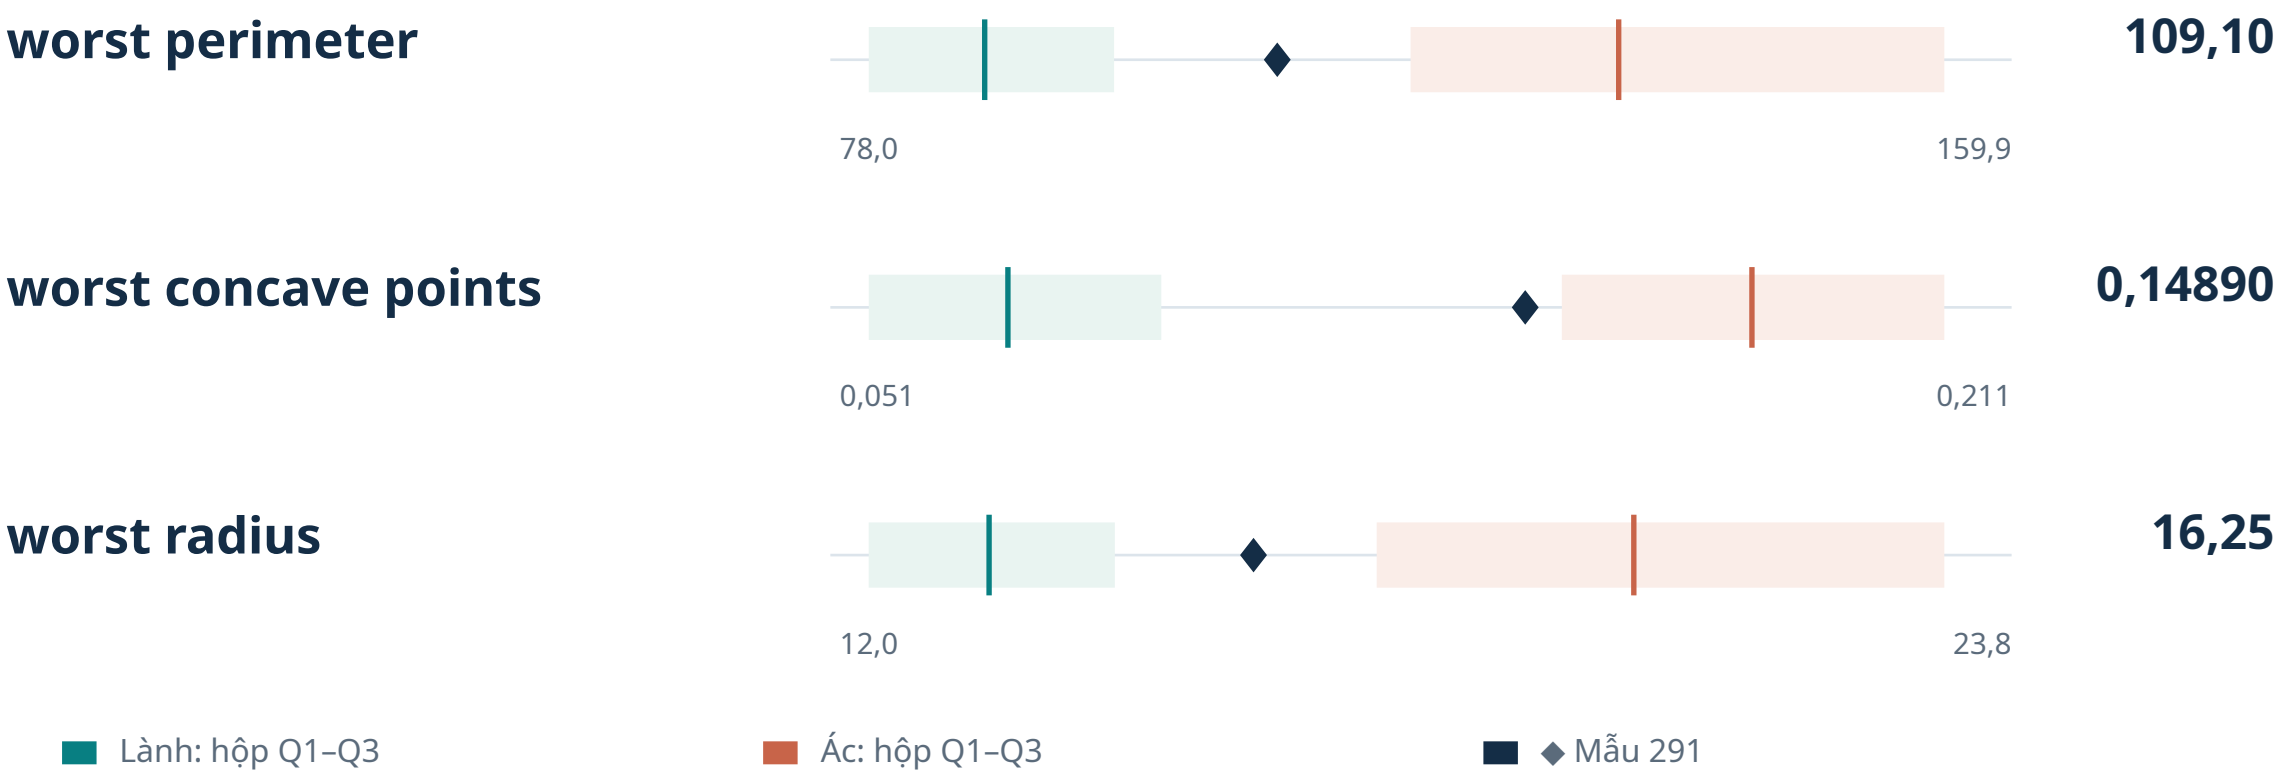


Đa số chọn ác → dương tính giả

Biên phiếu
3/51 ≈ 5,88%

Được chọn theo thứ tự test: đây là mẫu đầu tiên có hai phía phiếu, không chọn vì dễ giải thích.

Mẫu sai nằm giữa các vùng trung tâm của hai lớp



Mỗi hàng có thang riêng. Ba đặc trưng minh họa chưa đủ giải thích toàn bộ không gian 30 chiều.

Đối chứng 2 × 2 để tách hai yếu tố

XÉT ĐẶC TRƯNG	Hard voting	Soft voting
Toàn bộ	51 cây · cùng độ sâu	51 cây · cùng độ sâu
sqrt	51 cây · cùng độ sâu	51 cây · cùng độ sâu

Giữ chung: fold · bootstrap · seed từng cây. Hard/soft dùng cùng cây đã học.

Nhóm sqrt là Bagging tự xây có ngẫu nhiên hóa đặc trưng; không đồng nhất với RF sklearn.

Thay quy tắc tổng hợp chưa đem lại cải thiện

Xét đặc trưng	Tổng hợp	BA CV (%) · trung bình ± SD
Toàn bộ	**Hard**	**95,26 ± 2,45**
Toàn bộ	**Soft**	**95,26 ± 2,45**
sqrt	Hard	93,62 ± 3,48
sqrt	Soft	93,44 ± 3,77

All: hard/soft trùng 426 nhãn. Sqrt: khác nhau ở 1/426 quan sát.

Giữ hard voting và đổi all → sqrt: BA trung bình giảm 1,63 điểm phần trăm trong khảo sát.

controlled_comparison_summary.csv · balanced accuracy CV · 5 fold trên train

Đa dạng hơn chưa đủ: cây cơ sở cũng phải đủ tốt

BẤT ĐỒNG GIỮA CÁC CÂY

7,99%

→ 10,52%

D tăng khi dùng sqrt

CHẤT LƯỢNG MỘT CÂY

91,67%

→ 89,75%

Balanced accuracy trung bình giảm

Kết quả tổ hợp hard: 95,26% → 93,62%. Đây là quan sát trong cấu hình được kiểm soát.

controlled_comparison_summary.csv · số trung bình qua 5 fold

Kết quả có thể tái lập, nhưng kết luận có giới hạn

Chưa tuning riêng

Độ sâu chọn bằng cây đơn rồi dùng chung cho các mô hình.

Các holdout giao nhau

SD mô tả dao động; chưa phải khoảng tin cậy.

Phân tích bổ sung

Chỉ dùng train seed 42. Chưa đánh giá trên dữ liệu ngoài độc lập.

26/26 kiểm thử

github.com/Huyngaongow/hocmaygk

Bài minh họa phương pháp học máy; chưa đủ bằng chứng đánh giá hiệu quả chẩn đoán lâm sàng.

Ba kết luận từ dữ liệu đã khảo sát

01

Bagging cải thiện so với cây đơn

Accuracy cao hơn ở 9/10 lần chia; trung bình +1,96 điểm phần trăm.

02

Số cây cần được kiểm tra

Tăng từ 51 lên 101 cây chưa cải thiện BA CV trong thiết kế đã chạy.

03

Đa dạng đi cùng chất lượng

Các cây khác nhau hơn chưa bảo đảm tổ hợp dự đoán tốt hơn.

A. Cùng mẫu 291, hai cây đi tới hai nhãn

CÂY 1 → ÁC

1. worst radius ≤ 16,79500
2. worst concave points > 0,14315
3. worst symmetry > 0,28855

Lá: 18 lượt bootstrap, tất cả nhãn ác.

CÂY 2 → LÀNH

1. mean concave points ≤ 0,04989
2. worst symmetry > 0,16385
3. worst perimeter ≤ 127,20000

Lá: 256/259 lượt nhãn lành (98,84%).

Các lượt bootstrap có thể lặp hàng; độ thuần tại lá không bảo đảm đúng với quan sát mới.

B. Tính chỉ số với ác tính là lớp dương

Chỉ số	Công thức	Kết quả
Accuracy	(TP + TN) / N	136/143 = 95,10%
Precision ác	TP / (TP + FP)	49/52 = 94,23%
Recall ác	TP / (TP + FN)	49/53 = 92,45%
F1 ác	2TP / (2TP + FP + FN)	98/105 = 93,33%
Specificity	TN / (TN + FP)	87/90 = 96,67%
Balanced accuracy	Trung bình recall hai lớp	94,56%

Accuracy test, balanced accuracy CV và OOB là các phép đánh giá khác nhau.

C. Boosting và Stacking khác Bagging ở đâu?

BOOSTING

Học một chuỗi mô hình.
AdaBoost tăng trọng số tương đối cho mẫu dự đoán sai.
Gradient Boosting giảm hàm mất mát.

STACKING

Học mô hình tầng hai.
Đầu vào là dự đoán ngoài fold (OOF) của các mô hình cơ sở.
Tránh dùng dự đoán in-sample để học tầng hai.

Bagging đổi mẫu train để học các mô hình độc lập; hai hướng trên thay đổi cách phối hợp.

[3], [6], [7] · Chưa chạy thực nghiệm hai phương pháp này

D. Tài liệu tham khảo và cách tái lập

[1] Breiman (1996). Bagging Predictors. Machine Learning 24, 123–140.

[2] Breiman (2001). Random Forests. Machine Learning 45, 5–32.

[3] scikit-learn User Guide. Ensemble methods.

[4] scikit-learn API. load_breast_cancer.

[5] scikit-learn User Guide. Decision Trees.

[6] Freund & Schapire (1997). An Application to Boosting. JCSS 55(1).

[7] Wolpert (1992). Stacked Generalization. Neural Networks 5(2).

```
python de_5_ensemble_learning.py
python experiments/report_extensions.py
python experiments/controlled_comparison.py
```